

Laboratório 03: Caracterização da Atividade de Code Review no GitHub

André Xavier Lazarini
João Pedro Guimarães Ribeiro

15 de maio de 2026

Resumo

Este relatório apresenta uma análise quantitativa da atividade de *code review* em *pull requests* (PRs) do GitHub. A partir de um recorte dos dados coletados automaticamente via API REST, analisamos 16.646 PRs válidos distribuídos em 200 repositórios populares. O objetivo foi investigar como tamanho do PR, tempo de análise, descrição e interações se relacionam com o desfecho final da contribuição e com o esforço de revisão. Os resultados mostram que o tempo de análise e o volume de comentários são os sinais mais fortes de dificuldade de integração, enquanto o número de comentários também se destaca como o principal preditor do número de revisões.

1 Introdução

1.1 Contextualização

Em projetos colaborativos, o *code review* funciona como um mecanismo de controle de qualidade, compartilhamento de conhecimento e redução de risco antes da integração do código. No GitHub, esse processo acontece principalmente por meio de *pull requests*, que concentram discussões técnicas, revisões formais, pedidos de alteração e a decisão final de aceitar ou rejeitar uma contribuição.

1.2 Problema foco do experimento

Mesmo sendo uma prática amplamente adotada, a atividade de revisão não tem o mesmo comportamento para todos os PRs. Algumas contribuições são integradas rapidamente, enquanto outras acumulam comentários, revisões, tempo de espera e acabam fechadas sem merge. O problema investigado neste experimento é identificar quais características observáveis dos PRs estão mais associadas ao sucesso da integração e ao esforço de revisão.

1.3 Questões-problema ou questões de pesquisa

- **RQ01:** Qual a relação entre o tamanho do PR e o feedback final da revisão?
- **RQ02:** Qual a relação entre o tempo de análise e o status final do PR?
- **RQ03:** Como o tamanho da descrição do PR se relaciona com a probabilidade de merge?
- **RQ04:** Qual a relação entre o volume de interações e o desfecho final do PR?
- **RQ05:** Qual a relação entre o tamanho do PR e o número de revisões recebidas?
- **RQ06:** PRs que demoram mais para serem analisados recebem mais revisões?
- **RQ07:** Descrições mais longas se associam a mais ou menos revisões?
- **RQ08:** Qual a correlação entre interações sociais e o número de revisões formais?

1.4 Hipótese(s)

- **H1:** PRs maiores tendem a exigir mais revisões e ter menor chance de merge.
- **H2:** PRs que permanecem abertos por mais tempo têm maior chance de serem fechados sem merge.
- **H3:** Descrições mais detalhadas tendem a facilitar a integração e reduzir rodadas extras de revisão.
- **H4:** Mais comentários e participantes indicam maior complexidade, mais revisões e maior risco de rejeição.

1.5 Objetivo

Objetivo principal: caracterizar empiricamente a atividade de *code review* no GitHub a partir de métricas extraídas de PRs reais.

Objetivos específicos:

- medir como as métricas coletadas se distribuem entre PRs com merge e PRs fechados sem merge;
- avaliar a relação entre essas métricas e o número de revisões recebidas;
- comparar os resultados observados com as hipóteses iniciais;
- sintetizar implicações práticas e limitações do experimento.

2 Metodologia

2.1 Passo a passo do experimento

O experimento foi executado em quatro etapas:

1. seleção dos repositórios populares a partir da API do GitHub;
2. coleta de PRs fechados e revisados com autenticação via token;
3. limpeza dos dados para exclusão de bots e filtros de validade;
4. cálculo de medianas, tabelas-resumo, correlações de Spearman e gráficos.

2.2 Decisões

Algumas decisões metodológicas influenciam a leitura dos resultados:

- foi considerado apenas PR com pelo menos uma revisão humana;
- PRs com menos de uma hora entre criação e fechamento/merge foram descartados;
- contas automatizadas foram removidas da contagem de revisões;

2.3 Materiais utilizados

- API REST do GitHub;
- script Python `scripts/collect_github_prs.py`;
- bibliotecas `requests`, `pandas`, `scipy`, `matplotlib` e `seaborn`;
- ambiente local com exportação em CSV, PNG e LaTeX.

2.4 Métodos utilizados

O experimento adotou uma abordagem quantitativa, observacional e retrospectiva. Para resumir o comportamento dos PRs, utilizamos medianas por grupo. Para investigar associações monotônicas entre métricas e variáveis-alvo, utilizamos o coeficiente de Spearman (ρ), adequado para distribuições assimétricas e presença de *outliers*. Adotamos $p < 0,05$ como critério de significância estatística.

2.5 Métricas e suas unidades

Tabela 1: Métricas utilizadas no experimento

Métrica	Unidade	Interpretação
<code>files_changed</code>	arquivos	quantidade de arquivos alterados no PR
<code>analysis_time_hours</code>	horas	tempo entre criação e fechamento/merge
<code>description_length</code>	caracteres	tamanho do corpo textual do PR
<code>participants_count</code>	participantes	total de usuários únicos na discussão
<code>comments_total</code>	comentários	soma de comentários de <i>issue</i> e revisão
<code>reviews_count</code>	revisões	quantidade de revisões humanas registradas
<code>merged_flag</code>	binário	1 para merge e 0 para closed

3 Visualização dos Resultados

3.0.1 Visão geral do dataset

A Seção 4 foi atualizada diretamente a partir do arquivo `data/pull_requests_dataset.csv`, considerando o estado real do dataset no momento desta versão do relatório. O conjunto atual possui **16.746 PRs válidos**. Desse total, **12.044** PRs terminaram com merge e **4.702** foram fechados sem merge.

Tabela 2: Resumo do dataset real analisado

Indicador	Valor	Percentual
PRs válidos	–	100,00%
Repositórios distintos	–	–
PRs com merge	–	71,92%
PRs fechados sem merge	–	28,08%
Mediana de arquivos alterados	2	–
Mediana de tempo de análise	86,107 h	–
Mediana do tamanho da descrição	628 caracteres	–
Mediana de comentários	3	–

De forma agregada, o conjunto de dados mostra predominância de PRs integrados, mas ainda com uma parcela relevante de contribuições encerradas sem merge. Em termos centrais, o PR mediano do dataset possui 2 arquivos alterados, permanece pouco mais de 86 horas em análise, apresenta 628 caracteres de descrição e acumula 3 comentários ao longo do processo.

3.0.2 Tabelas-resumo por grupo

Resultados por status final do PR. Para responder às questões de pesquisa relacionadas ao feedback final da revisão, comparamos as medianas das métricas entre PRs com

`merged` e PRs com `closed`. As maiores diferenças entre os grupos aparecem no tempo de análise e no volume de interações, enquanto o tamanho medido por arquivos alterados e o número de participantes permanecem praticamente estáveis.

Tabela 3: Medianas das métricas por status final do PR

Métrica	Merged	Closed
<code>files_changed</code>	2	2
<code>analysis_time_hours</code>	44,312	1.035,999
<code>description_length</code>	632,5	620
<code>participants_count</code>	3	3
<code>comments_total</code>	2	4
<code>reviews_count</code>	1	1

Resultados por faixa de revisões. Para a dimensão de esforço de revisão, os PRs foram agrupados em três faixas: 1 revisão, 2 revisões e 3 ou mais revisões. Os resultados mostram crescimento monotônico em tempo de análise, descrição, participantes e comentários, indicando que PRs com mais rodadas de revisão tendem também a exigir mais coordenação e maior permanência em aberto.

Tabela 4: Medianas das métricas por faixa de revisões recebidas

Métrica	1 revisão	2 revisões	3+ revisões
<code>files_changed</code>	2	2	3
<code>analysis_time_hours</code>	52,083	96,923	211,665
<code>description_length</code>	529	674	853
<code>participants_count</code>	3	3	4
<code>comments_total</code>	1	3	9

O padrão mais forte no resumo descritivo aparece em `comments_total`, cuja mediana cresce de 1 para 9 entre a primeira e a última faixa. O mesmo comportamento ocorre com o tempo de análise, que quadruplica entre PRs com uma única revisão e PRs com três ou mais revisões.

3.0.3 Correlações estatísticas

Correlações com o status final. As correlações de Spearman abaixo foram recalculadas diretamente a partir do CSV real. A tabela apresenta a associação entre cada métrica e a variável binária de desfecho (`merged_flag`), considerando 1 para merge e 0 para fechamento sem merge.

Tabela 5: Correlações de Spearman entre métricas e status final

Métrica	ρ	p -valor	n
files_changed	0,0716	< 0,001	16.746
analysis_time_hours	-0,4187	< 0,001	16.746
description_length	0,0133	0,0849	16.746
participants_count	-0,0766	< 0,001	16.746
comments_total	-0,1480	< 0,001	16.746

Entre as métricas analisadas, **analysis_time_hours** apresentou a associação mais forte com o status final, com correlação moderada negativa. Isso indica que PRs mais demorados tendem, com maior frequência, a terminar fechados sem merge. O total de comentários também exibiu correlação negativa estatisticamente significativa, embora com intensidade menor. Já o tamanho da descrição não apresentou relação estatisticamente significativa com o desfecho final.

Correlações com o número de revisões. Para o esforço de revisão, as correlações foram calculadas entre as métricas do PR e **reviews_count**. Nesse caso, todas as métricas observadas apresentaram associações positivas e estatisticamente significativas.

Tabela 6: Correlações de Spearman entre métricas e número de revisões

Métrica	ρ	p -valor	n
files_changed	0,2249	< 0,001	16.746
analysis_time_hours	0,1839	< 0,001	16.746
description_length	0,1128	< 0,001	16.746
participants_count	0,3706	< 0,001	16.746
comments_total	0,5862	< 0,001	16.746

O principal destaque desse bloco foi **comments_total**, que apresentou a correlação mais alta de toda a análise ($\rho = 0,5862$). Isso sugere que o volume de interações sociais está fortemente associado ao aumento do número de revisões formais. Participantes e tempo de análise também mostraram relações positivas relevantes, ainda que menos intensas.

4 Discussão dos resultados

4.1 Confrontar questões-pesquisa

4.1.1 RQ01: tamanho do PR e feedback final

No snapshot atual, a relação entre tamanho e desfecho final aparece fraca quando o tamanho é medido por **files_changed**. A correlação foi positiva, mas muito pequena ($\rho = 0,0698$), e as medianas de merged e closed ficaram idênticas em 2 arquivos. Isso

sugere que, com os dados disponíveis agora, o número de arquivos sozinho não separa bem PRs aceitos de PRs rejeitados.




Figura 1: RQ01: tamanho do PR vs status final.

4.1.2 RQ02: tempo de análise e status final

PRs fechados sem merge ficaram muito mais tempo abertos que PRs integrados: 1041,689 horas contra 44,669 horas em mediana. O coeficiente de Spearman moderado e negativo ($\rho = -0,4184$) reforça a ideia de que demora prolongada costuma estar associada a dificuldades de integração, retrabalho ou perda de prioridade.




Figura 2: RQ02: tempo de análise vs status final.

4.1.3 RQ03: descrição do PR e chance de merge

O tamanho da descrição praticamente não se relacionou com o status final. As medianas foram muito próximas, com leve vantagem para PRs com merge (631 contra 621 caracteres), mas a correlação foi desprezível e estatisticamente não significativa ($\rho = 0,0121$, $p = 0,1184$). Assim, neste snapshot, o tamanho da descrição não se sustenta como indicador de sucesso de integração.




Figura 3: RQ03: descrição do PR vs status final.

4.1.4 RQ04: interações e desfecho do PR

O total de comentários se mostrou mais informativo que o tamanho da descrição e que o número de arquivos. PRs fechados sem merge apresentaram mediana de 4 comentários, contra 2 dos PRs com merge. A correlação negativa ($\rho = -0,1482$) ainda é fraca, mas aponta que interações mais intensas tendem a acompanhar PRs com maior atrito no processo de revisão.




Figura 4: RQ04: interações vs status final.

4.1.5 RQ05: tamanho do PR e número de revisões

Quando observamos o esforço de revisão, o tamanho medido em arquivos alterados passa a mostrar um padrão mais claro. A mediana permanece em 2 arquivos para PRs com 1 ou 2 revisões, mas sobe para 3 arquivos em PRs com 3 ou mais revisões. A correlação ($\rho = 0,2254$) é fraca, porém consistente com a hipótese de que contribuições maiores tendem a exigir mais ciclos de validação.




Figura 5: RQ05: tamanho do PR vs número de revisões.

4.1.6 RQ06: tempo de análise e número de revisões

O tempo de análise cresce de forma monotônica conforme o número de revisões aumenta: 52,749 horas para 1 revisão, 97,750 para 2 revisões e 212,922 para 3 ou mais revisões. A correlação positiva ($\rho = 0,1827$) sugere que processos com mais rodadas também tendem a ser mais longos, embora a magnitude permaneça fraca.




Figura 6: RQ06: tempo de análise vs número de revisões.

4.1.7 RQ07: descrição do PR e número de revisões

Descrições mais longas apareceram associadas a mais revisões, e não a menos revisões. A mediana cresce de 529 para 672 e depois para 851 caracteres conforme o PR recebe mais rodadas de revisão. A correlação positiva ($\rho = 0,1127$) é pequena, mas enfraquece a hipótese de que detalhamento textual, isoladamente, reduz o esforço de revisão.




Figura 7: RQ07: descrição do PR vs número de revisões.

4.1.8 RQ08: interações sociais e número de revisões

O total de comentários cresce de 1 para 3 e depois para 9 na mediana, enquanto a correlação chega a $\rho = 0,5855$, a mais alta observada. Isso indica que PRs com muitas interações tendem fortemente a concentrar mais rodadas de revisão, servindo como um indicador operacional de complexidade e retrabalho.




Figura 8: RQ08: interações sociais vs número de revisões.

4.2 Insights

- tempo de análise e comentários foram muito mais informativos que o simples número de arquivos alterados para diferenciar PRs aceitos de PRs rejeitados;
- o maior marcador de esforço de revisão foi o volume de interações, não a descrição textual;
- descrições maiores não significaram integração mais fácil; elas parecem acompanhar PRs mais complexos;
- os resultados de tamanho ficaram limitados porque as métricas de linhas alteradas não foram aproveitáveis neste snapshot.

4.3 Comparações

Em termos relativos, a diferença mais expressiva do bloco de status ocorreu em tempo de análise: PRs fechados ficaram abertos cerca de 23 vezes mais tempo do que PRs com merge em mediana. No bloco de revisões, a maior variação ocorreu nos comentários, que foram 9 vezes maiores em PRs com 3 ou mais revisões do que em PRs com apenas uma revisão.

4.4 Estatísticas

Os coeficientes de Spearman indicaram:

- associação moderada negativa entre tempo de análise e merge ($\rho = -0,4184$);
- associação fraca negativa entre comentários e merge ($\rho = -0,1482$);
- associação moderada positiva entre comentários e número de revisões ($\rho = 0,5855$);
- associações fracas positivas entre arquivos alterados, tempo e descrição com o número de revisões.

5 Conclusão

Com base no snapshot analisado, o sucesso do *pull request* está mais associado à rapidez do processo e ao menor volume de interações do que ao tamanho textual de sua descrição, o que converge com a literatura clássica sobre revisão de código. A quantidade de comentários e o tempo prolongado em aberto revelaram-se os principais indicadores de esforço de revisão e de risco de fechamento sem merge, justificando a decisão prática de priorizar contribuições de menor escopo conversacional e operacional. Para aprimorar essas análises e evitar variações temporais, trabalhos futuros devem focar em corrigir a coleta de métricas relacionadas à contagem de linhas alteradas, segmentar os resultados segundo características específicas dos repositórios e linguagem, além de investigar qualitativamente as discussões e testar modelos preditivos de risco.